KUALITAS UDARA
KOTA ASIA TENGGARA

Exploratory Data Analysis | Tugas Besar Visualisasi Data

Identitas mahasiswa / kelompok: isi sebelum dikumpulkan.

1,227 catatan kota · 9 negara · 4 subindeks polutan

1. Latar belakang dan pertanyaan

Polusi udara merupakan kasus nyata yang berdampak pada kesehatan. Dataset ini menyediakan indeks kualitas udara kota untuk mengeksplorasi variasi nilai AQI. Analisis bertujuan menggambarkan distribusi AQI, membandingkan catatan kota menurut negara, dan menelaah hubungan beberapa subindeks polutan secara bersamaan.

Pertanyaan: Bagaimana sebaran dan kategori AQI? Bagaimana variasi distribusi AQI antarnegara yang tersedia? Bagaimana hubungan CO, ozon, NO2, dan PM2.5, serta kaitannya dengan AQI total?

2. Data dan metode

Dataset global berisi 23.463 baris dan 12 kolom. Sumber input: halaman Kaggle notebook kimpilso yang diberikan pengguna (tautan lengkap pada bagian referensi). CSV berasal dari ZIP unggahan dan dipertahankan tanpa perubahan. Unit analisis adalah catatan kota; indeks polutan bukan konsentrasi fisik.

Nama Viet Nam dan Lao People's Democratic Republic disamakan dengan Vietnam dan Laos sebelum filter. Cakupan memakai sepuluh negara filter notebook referensi; Brunei tidak tersedia. Subset bukan representasi lengkap wilayah atau daftar keanggotaan ASEAN saat ini.

Tidak ada tanggal pengukuran, metode sensor, atau bobot penduduk. Hasil tidak menunjukkan keadaan udara terkini, tren waktu, peringkat nasional resmi, maupun hubungan sebab-akibat.

3. Audit kualitas dan cakupan

Data global mempunyai 427 negara kosong dan satu kota kosong; tidak ada duplikat baris penuh. Seluruh nilai numerik nonnegatif. Subset regional tidak memiliki nilai kosong. Negara kosong tidak ditebak; nilai ekstrem tidak dibuang atau diwinsorisasi tanpa bukti kesalahan.

Negara	n kota	Median AQI	Rata-rata AQI
Singapore	1	91.0	91.0
Indonesia	379	74.0	93.0
Malaysia	125	72.0	81.6
Vietnam	60	69.0	87.0
Philippines	337	54.0	61.2
Thailand	246	50.5	53.6
Cambodia	12	46.0	45.2
Laos	8	43.5	43.5
Myanmar	59	34.0	40.2

Ketimpangan cakupan

Indonesia memiliki 379 catatan, sedangkan Singapore hanya satu. Setiap kota berbobot sama; hasil agregat tidak dibobot menurut penduduk. Nilai tunggal Singapore tidak cukup untuk menyatakan distribusi nasional.

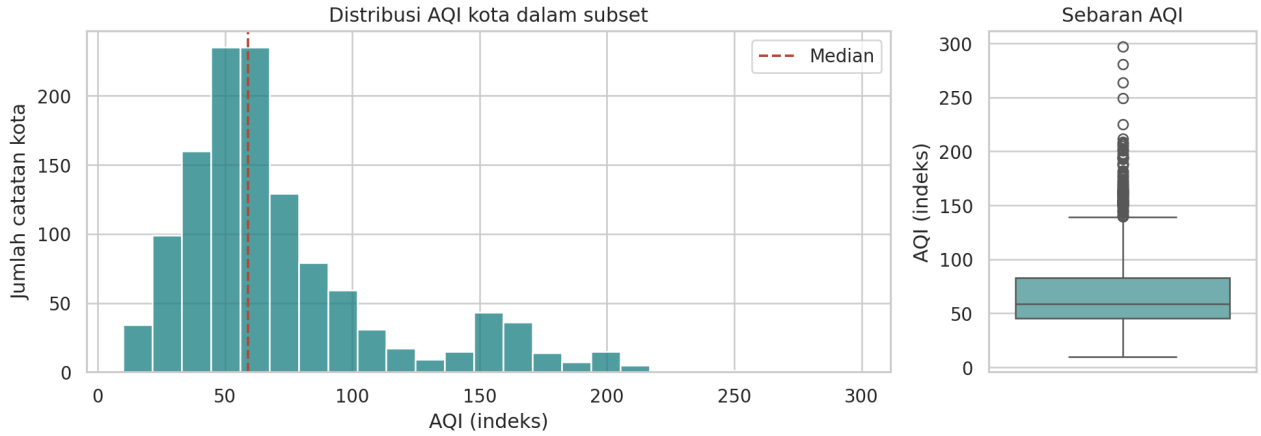
Ketidakkonsistenan label kategori

Audit interval AQI tanpa celah menemukan 12 label yang berbeda dari kategori numerik pada nilai batas 100 dan 150. Label asli tetap digunakan untuk distribusi kategori, sedangkan proporsi AQI >100 dihitung langsung dari angka AQI. Rincian disimpan di data/audit_kategori.csv. Nilai dan label asli tidak ditimpa.

Variabel dan pendekatan

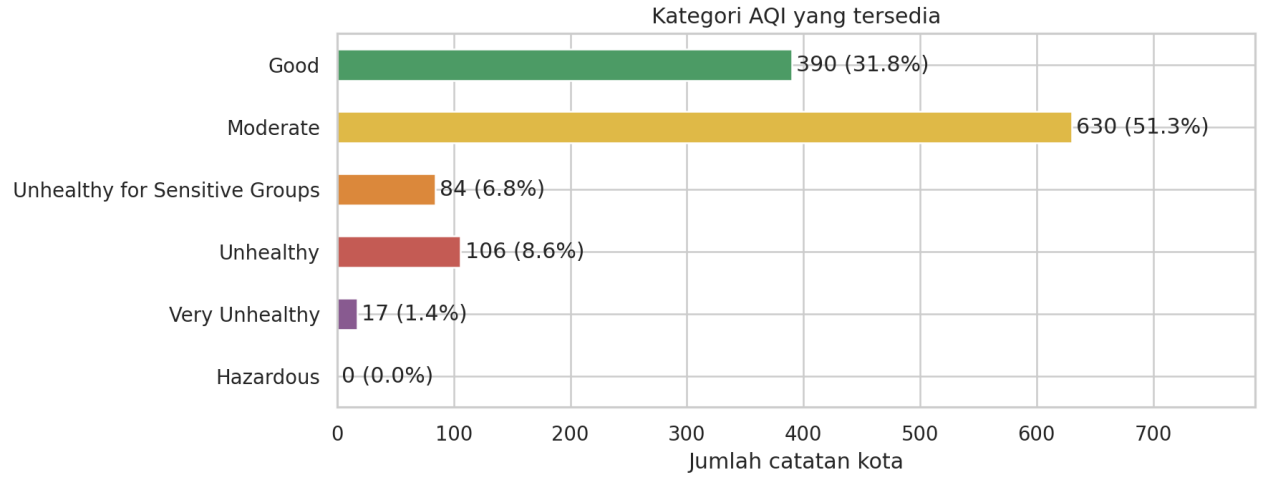
Univariate: histogram, boxplot, dan frekuensi kategori. Bivariate: distribusi AQI menurut negara dan scatterplot PM2.5–AQI total. Multivariate: scatterplot CO–PM2.5 berwarna negara, matriks korelasi Spearman, dan profil median empat polutan per negara. Analisis bersifat deskriptif tanpa uji kausal atau model prediksi.

4. Univariate: bentuk distribusi AQI



Gambar 1. Histogram dan boxplot AQI asli pada subset regional. Garis putus-putus menunjukkan median.

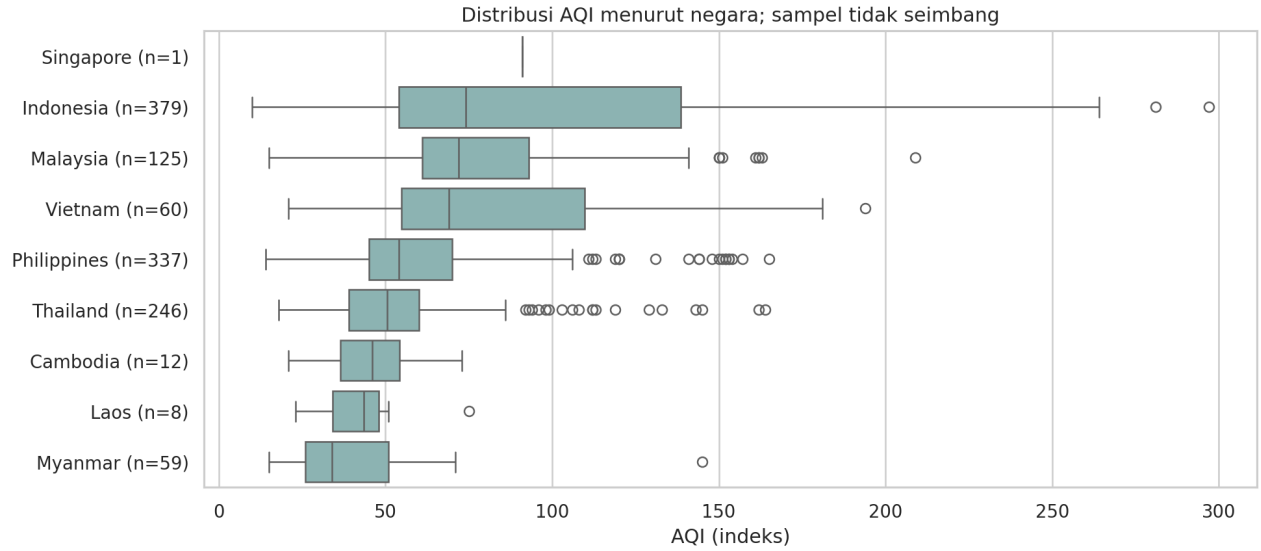
Median AQI adalah **59.0** dan rata-rata **71.6**. Rata-rata di atas median konsisten dengan ekor kanan. Nilai ekstrem tetap dipertahankan karena mungkin menunjukkan kondisi polusi tinggi dalam sampel, bukan otomatis kesalahan pencatatan.



Gambar 2. Frekuensi dan persentase label kategori asli.

Moderate mendominasi: **630 kota (51,3%)**, diikuti Good: **390 (31,8%)**. Berdasarkan angka AQI, **16.5%** catatan bernilai >100. Persentase catatan kota tidak sama dengan persentase penduduk terpapar; ketidakkonsistenan label batas juga membuatnya berbeda dari jumlah kategori di atas Moderate.

5. Bivariate: negara dan AQI



Gambar 3. Distribusi AQI menurut negara, diurutkan berdasarkan median dan disertai ukuran sampel.

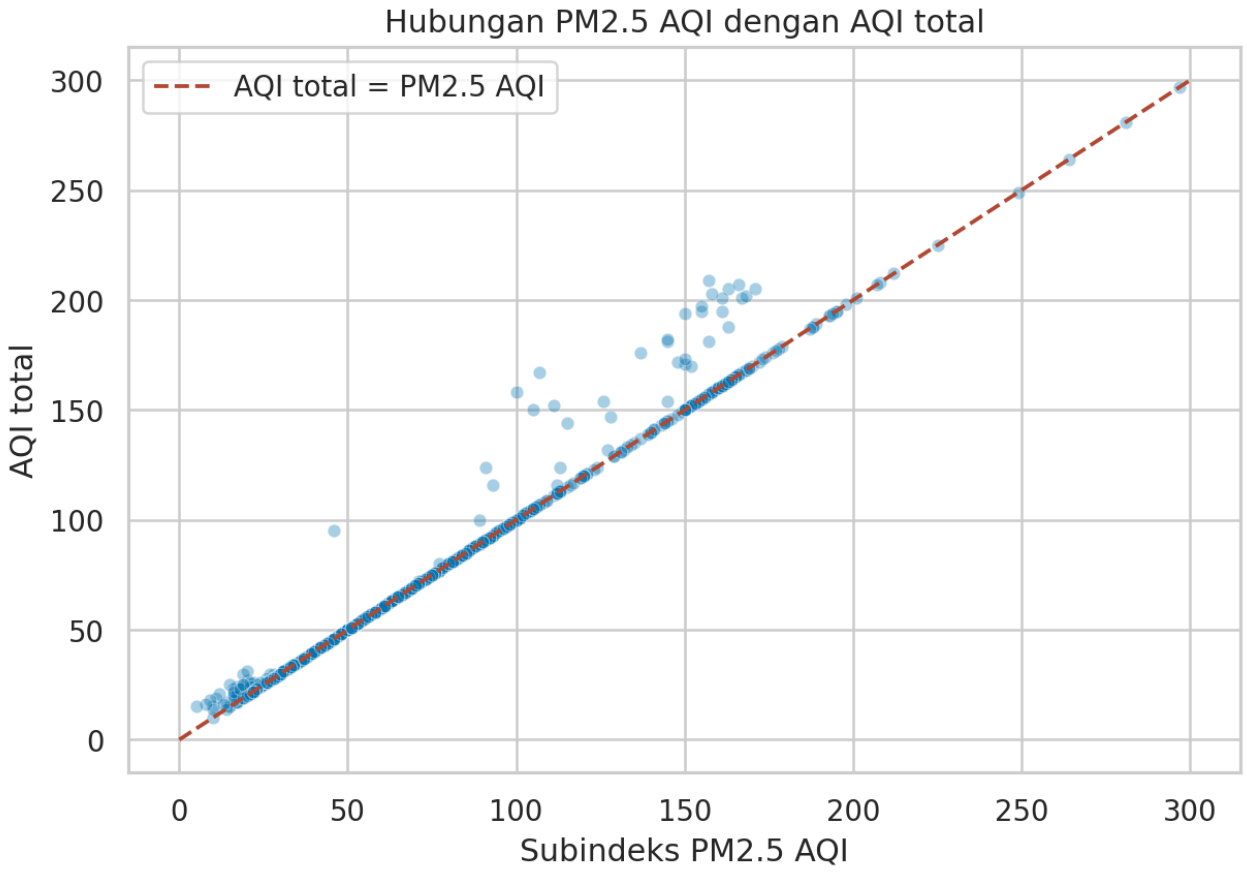
Di antara negara dengan lebih dari satu catatan, Indonesia memiliki median tertinggi (74,0), disusul Malaysia (72,0). Myanmar memiliki median terendah (34,0). Singapore bernilai 91,0 tetapi hanya berasal dari satu catatan, sehingga tidak dapat dibandingkan sebagai distribusi yang stabil.

Boxplot memperlihatkan sebaran antarkota yang tidak tercakup oleh satu rata-rata. Indonesia dan Vietnam mempunyai nilai tinggi di bagian ekor distribusi; temuan ini layak ditelusuri dengan metadata waktu dan lokasi pengukuran.

Batas interpretasi

Cakupan kota tidak seimbang dan cara pemilihan kota tidak diketahui. Karena itu, urutan median adalah ringkasan subset yang tersedia, bukan peringkat nasional yang representatif. Tidak ada dasar dari data ini saja untuk menyimpulkan bahwa kebijakan atau sumber emisi tertentu menyebabkan perbedaan negara.

6. Bivariate: PM2.5 dan AQI gabungan



Gambar 4. PM2.5 AQI terhadap AQI total; garis diagonal adalah kesamaan nilai.

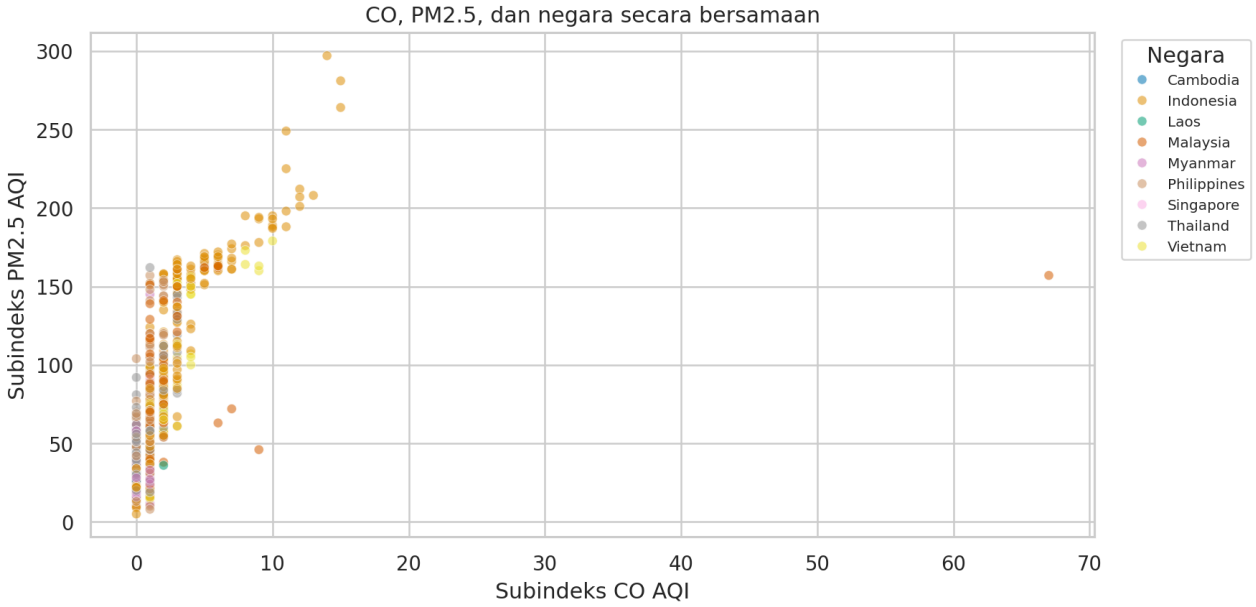
Korelasi Pearson PM2.5–AQI total adalah **0.990**. AQI total menyamai PM2.5 AQI pada **93.5%** catatan, termasuk kemungkinan nilai seri dengan polutan lain.

Pada **100%** baris subset, AQI total persis sama dengan maksimum empat subindeks. Ini merupakan temuan struktural penting: hubungan tinggi dengan salah satu komponen tidak berdiri sendiri sebagai penemuan kausal.

Implikasi analitis

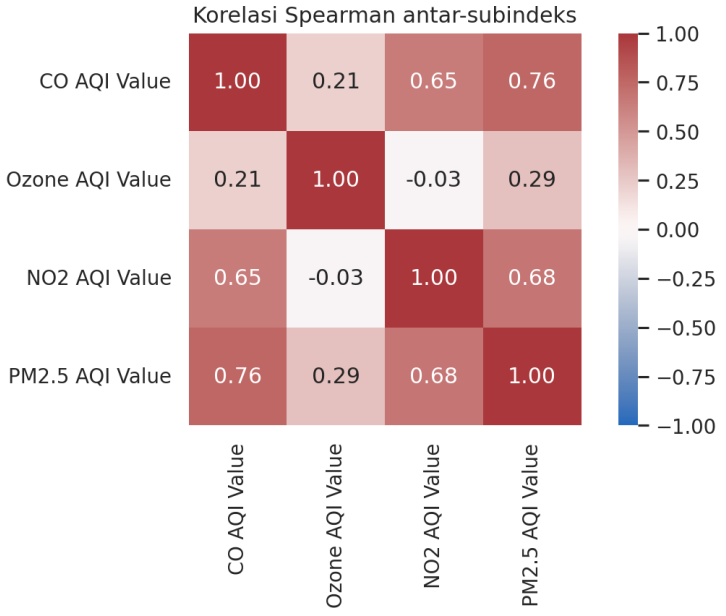
Model prediksi AQI total dari keempat subindeks berpotensi hanya mempelajari definisi indeks. Oleh sebab itu, EDA ini menitikberatkan distribusi dan hubungan antarsubindeks. Klaim bahwa PM2.5 menjadi penyebab seluruh variasi kualitas udara atau identifikasi sumber emisi tidak didukung oleh analisis korelasi ini.

7. Multivariate: CO, PM2.5, dan negara



Gambar 5. Dua subindeks sebagai sumbu, negara sebagai warna; tiga variabel dipetakan bersamaan.

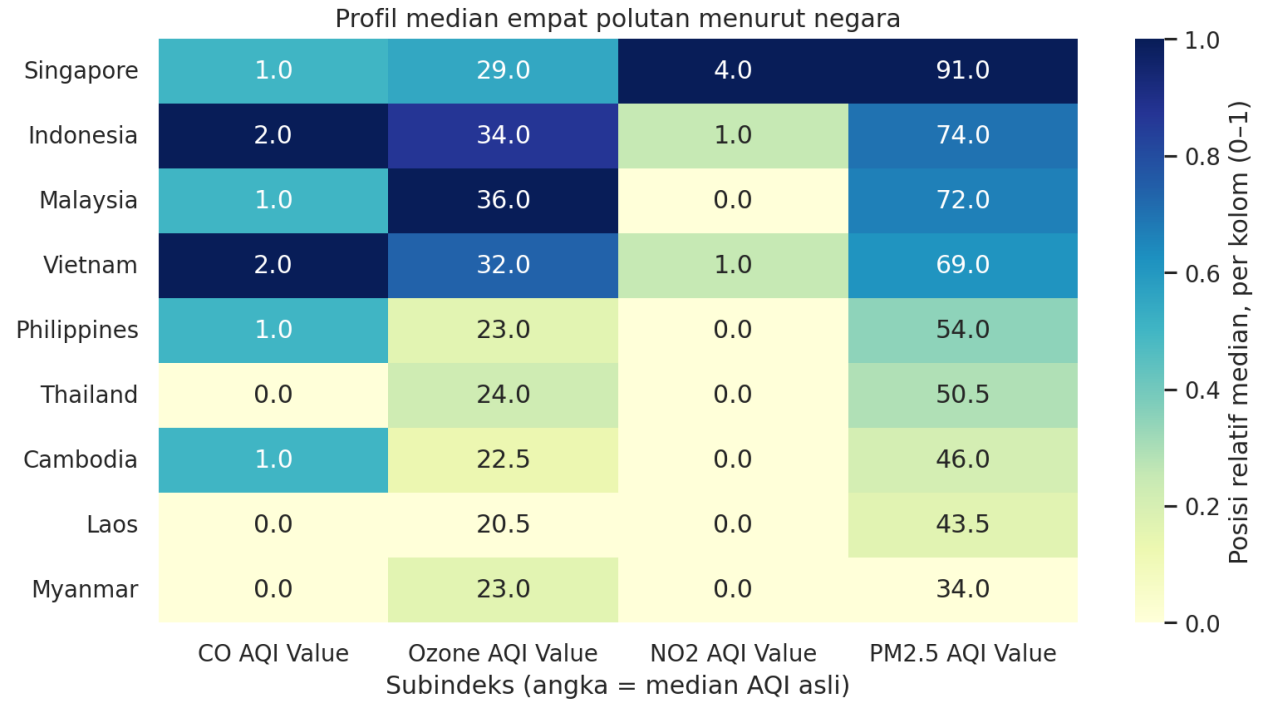
Banyak catatan mengelompok pada nilai CO AQI yang kecil, sementara PM2.5 AQI menyebar lebar. Warna menunjukkan asal negara dan memungkinkan penelaahan apakah pola gabungan didominasi kelompok tertentu. Tumpang tindih titik dan jumlah kota yang berbeda membatasi pembacaan langsung.



Gambar 6. Korelasi Spearman empat polutan: merangkum asosiasi peringkat dan lebih toleran terhadap distribusi miring.

Hubungan peringkat positif tidak mengungkap sumber emisi. Hubungan gabungan juga dapat berbeda dari hubungan di dalam negara; penelitian lanjutan perlu mengendalikan waktu, lokasi, dan cara pengukuran.

8. Profil multivariat dan kesimpulan



Gambar 7. Angka adalah median AQI asli; warna dinormalisasi 0–1 secara terpisah pada setiap kolom.

Profil median memperlihatkan perbedaan gabungan empat subindeks antarkelompok negara. Normalisasi warna membantu melihat variasi CO/NO2 meskipun angkanya jauh lebih kecil dari PM2.5. Warna yang sama antarpolutan tidak berarti nilai AQI aslinya sama; angka anotasi menjadi acuan nilai.

Kesimpulan

AQI sampel memiliki ekor kanan dan label Moderate paling umum. Perbedaan antarkota dan negara terlihat, tetapi ukuran sampel yang timpang membatasi generalisasi. Hubungan PM2.5 dengan AQI gabungan harus dibaca bersama sifat maksimum subindeks. Profil beberapa polutan menambah konteks yang tidak didapat dari AQI total saja.

Tindak lanjut yang didukung data

Verifikasi asal, lisensi, metode, dan waktu pengukuran; gunakan sampel kota yang sebanding; tambahkan bobot penduduk bila tujuan analisis adalah paparan. Nilai ekstrem perlu ditelusuri ke sumber primer sebelum menyusun intervensi. Dataset ini tidak cukup untuk menetapkan tren atau penyebab emisi spesifik.

9. Reproduksibilitas dan referensi

Notebook memuat data lokal dan dapat dijalankan seluruhnya tanpa koneksi internet setelah dependensi tersedia. Dataset asli, subset, audit kategori, ringkasan negara, dan tujuh gambar disertakan. Versi paket tersedia pada requirements.txt. Notebook, report, dan slides berasal dari hasil eksekusi yang sama.

Langkah menjalankan ulang

Buka folder submission sebagai direktori kerja, pilih kernel Python (Visdat), lalu jalankan semua sel notebook. Di lingkungan yang disiapkan, gunakan petunjuk /workspace/setup/README.md. Berkas data/hasil_ringkas.json menyimpan statistik dasar untuk pemeriksaan silang.

Referensi data dan adaptasi

Kaggle, kimpilso: ASEAN Air Pollution Capstone G5 DS Greatedu, halaman Input. Tautan diberikan pengguna; halaman penerbit belum diinspeksi langsung. Tautan ini merujuk notebook/input, bukan verifikasi atribusi pengumpulan data primer.

https://www.kaggle.com/code/kimpilso/asean-air-pollution-capstone-g5-ds-greatedu/input

Notebook referensi unggahan: asean-air-pollution-capstone-g5-ds-greatedu.ipynb. Dataset unggahan: global_air_pollution_dataset.csv.zip. Kode EDA disusun ulang, filter nama negara diperbaiki, dan output dihitung ulang.

SHA256 CSV asli:

e1fc6e682edb8a2102d87e182b844fc8cde49e10763c0ef4293e510bbe240f69

Catatan sebelum pengumpulan

Isi identitas mahasiswa/kelompok. Periksa halaman input Kaggle untuk tautan dataset spesifik, atribusi penyedia, lisensi, dan periode koleksi. Jangan menambahkan tanggal pengukuran atau sumber primer yang tidak didukung metadata. Review kesesuaian gaya sitasi dan format LMS institusi.